Môn Trí tuệ nhân tạo (61FIT3AIN), project giữa kỳ số 12

# Campus FAQ Assistant

Tìm đúng câu trả lời trong 112 FAQ và thông báo của trường bằng TF-IDF, Logistic Regression và quy tắc từ chối khi không đủ liên quan.

How do I reset my Sutdent Portal password?

faq_technical_support_01
How do I reset my Student Portal password?

cosine 0,53
technical_support, tin cậy 90%


**Nguyễn Đạt Vinh** (nhóm trưởng) 2301040198
**Lương Việt Anh** 2301040004
**Nguyễn Ánh Dương** 2401040080

Trường Đại học Hà Nội, tháng 11/2026

# Hệ thống phải tìm đúng tài liệu, hoặc nói thẳng là không có

| Câu hỏi người dùng gõ | Hệ thống phải | Kết quả mong muốn |
|---|---|---|
| `How do I reset my Student Portal password?` | Tìm đúng FAQ | faq_technical_support_01 |
| `How do I reset my Sutdent Portal password?` | Vẫn tìm đúng dù gõ sai | faq_technical_support_01 |
| `What's the best restaurant near campus for vegan food?` | Từ chối, không bịa | Information not found |

`classify_intent(query)`

Trả về một trong 7 intent kèm độ tin cậy, ví dụ `("exam", 0.82)`.

`retrieve(query, top_k)`

Trả về tối đa k cặp (tài liệu, điểm), hoặc danh sách rỗng khi không đủ liên quan.

**Ràng buộc của đề**

Chỉ phương pháp cổ điển, chạy offline bằng scikit-learn, không gọi API LLM.

# 120 câu test được thiết kế để đánh vào ba điểm yếu của việc so khớp từ

## Dữ liệu của đề

112 tài liệu: 84 FAQ và 28 thông báo, chia đều cho 7 intent (16 tài liệu mỗi intent): course_registration, exam, tuition, class_schedule, student_services, graduation, technical_support.

## Bộ 120 câu test



| 35 | 35 | 35 | 15 |
|---|---|---|---|
| normal | paraphrase | typo | ngoài phạm vi |

normal = chép nguyên câu hỏi FAQ; mỗi câu normal có thêm 1 bản paraphrase và 1 bản typo.

### Lệch từ vựng (paraphrase)

Cùng ý nhưng khác chữ, máy so từ không thấy giống nhau.

`section is full` và `no open seats`

### Gõ sai (typo)

So nguyên từ thì "conncet" là một từ hoàn toàn mới.

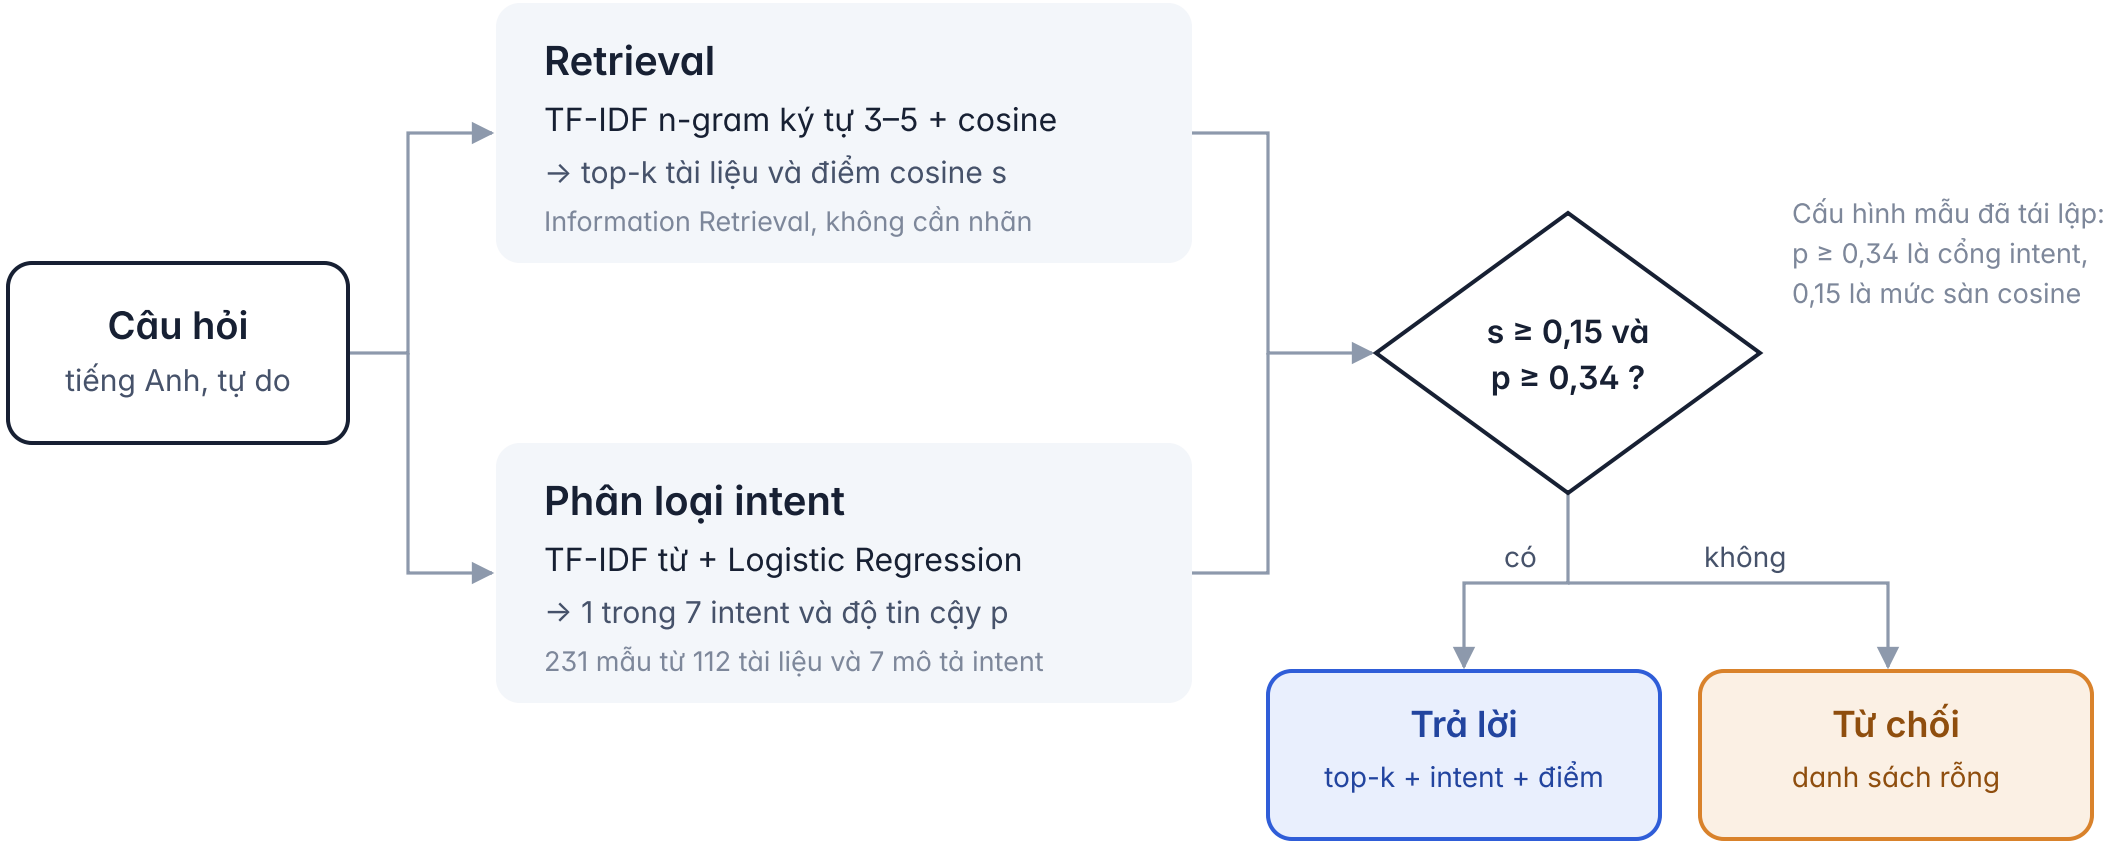
`connect` và `conncet`

### Trùng từ tình cờ (ngoài phạm vi)

Câu không liên quan có thể chung đặc trưng với kho nên vẫn có điểm khác 0.

`Can I rent a kayak from the campus recreation center?`

# Hai nhánh cho điểm tài liệu và intent, rồi kiểm tra điều kiện từ chối




Train: 112 text + 112 question/title + 7 mô tả. p là posterior cao nhất trong 7 intent.

# TF-IDF hạ trọng số của từ phổ biến; cosine đo hướng của vector, không đo độ dài

$$\text{tfidf}(t,d) = \text{tf}(t,d) \times \left( \ln \frac{1+N}{1+\text{df}(t)} + 1 \right)$$

Sublinear TF = 1 + ln(count) khi count > 0. IDF có smoothing; vector được chuẩn hóa L2. N = 112.

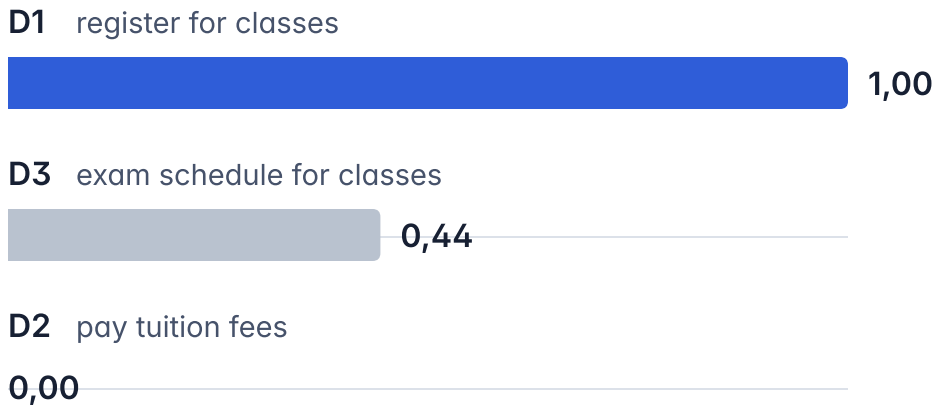
$$\cos\left(\vec{q},\vec{d}\right) = \frac{\vec{q}\cdot\vec{d}}{\|\vec{q}\|\ \|\vec{d}\|}$$

Cosine so hướng sau khi chuẩn hóa độ dài vector. Thêm đặc trưng mới vẫn có thể làm đổi điểm.

> N-gram ký tự 3–5: “connect” và “conncet” không chung từ nào, nhưng vẫn chung các cụm “ co”, “con”, “onn”.

## Ví dụ dùng cùng IDF có smoothing, N = 3

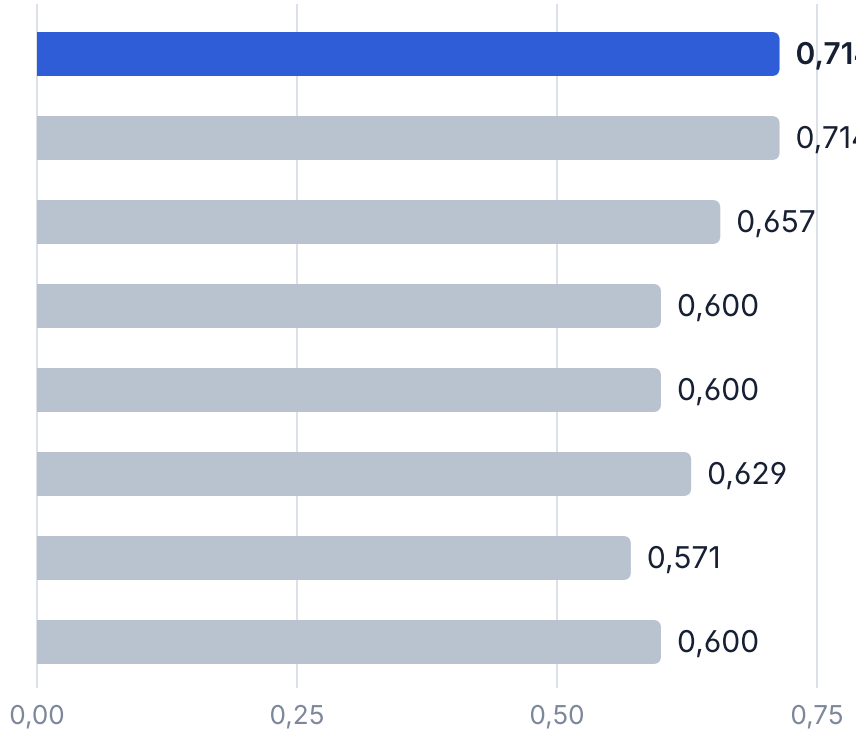
Câu hỏi `how to register for classes`




> Với công thức IDF có smoothing bên trái, D3 được 0,44 và xếp sau D1. Câu hỏi được chiếu vào bộ từ vựng của kho.

# Char 3–5 đứng đầu tám cấu hình được trình bày, với MRR 0,943

| Phương pháp (xếp theo MRR) | P@1 với 35 câu diễn đạt lại | MRR, 105 câu |
|---|---|---|
| **TF-IDF n-gram ký tự 3–5** | **0,714** | **0,943** |
| Hybrid: 0,5 từ + 0,5 ký tự | 0,714 | 0,936 |
| TF-IDF từ | 0,657 | 0,927 |
| BM25 (k1 = 1,5, b = 0,75) | 0,600 | 0,912 |
| TF-IDF từ, 1–2 gram | 0,600 | 0,905 |
| TF-IDF từ, bỏ stopword + sublinear | 0,629 | 0,896 |
| Bag-of-Words + cosine (baseline) | 0,571 | 0,893 |
| LSA (TF-IDF + SVD 60 chiều) | 0,600 | 0,873 |

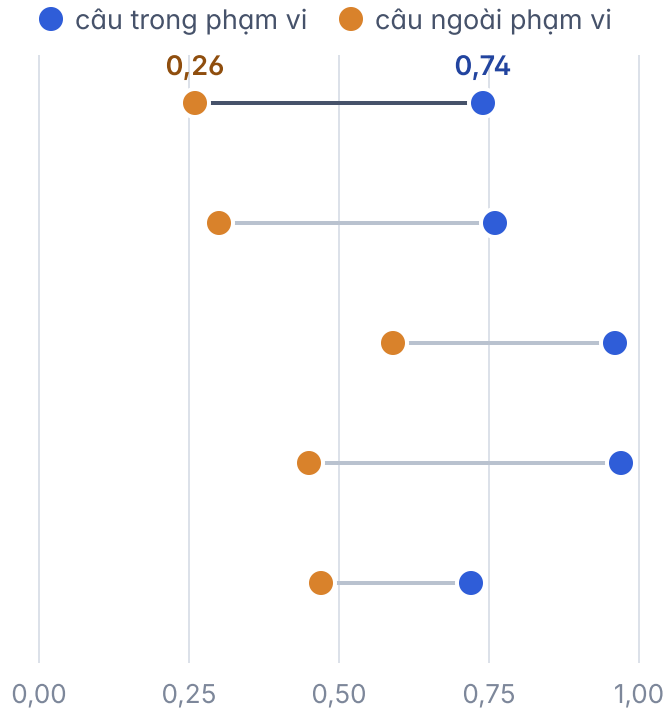



> Char 2–4 đạt MRR 0,953 và P@1 92,4% trên cùng benchmark. Nhóm giữ 3–5 để nhất quán với code mẫu và demo; đây chưa phải kết quả chọn mô hình trên dữ liệu độc lập.

Bảng so sánh từ tài liệu nghiên cứu của nhóm; cấu hình cuối được tái lập bằng scripts/evaluate.py.

# Logistic Regression đúng 97,1% intent và ít tự tin nhất với câu ngoài phạm vi

| Mô hình | Đúng | Độ tin cậy trung bình |
|---|---|---|
| **TF-IDF + Logistic Regression** | **97,1%** | |
| TF-IDF ký tự + Logistic Regression | 97,1% | |
| TF-IDF ký tự + Naive Bayes | 96,2% | |
| BoW + Naive Bayes (baseline) | 94,3% | |
| kNN (k = 5, cosine) | 87,6% | |




$$P\left(c \mid \vec{x}\right) = \frac{\exp\left(\vec{w}_c \cdot \vec{x} + b_c\right)}{\sum_k \exp\left(\vec{w}_k \cdot \vec{x} + b_k\right)}$$

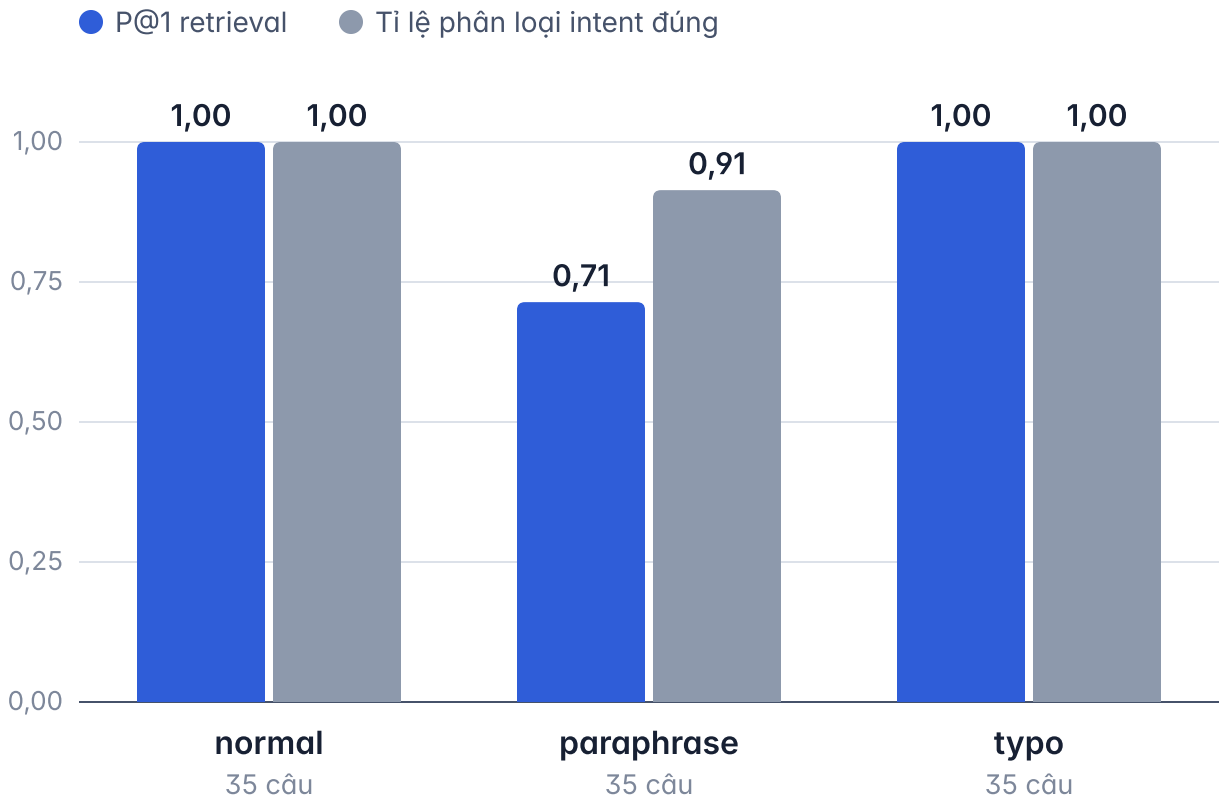
Logistic Regression là mô hình **phân biệt**: học thẳng ranh giới giữa 7 intent.

Naive Bayes là mô hình **sinh**, giả định độc lập có điều kiện. BoW + NB có confidence OOC trung bình 0,45 trên benchmark này.

LinearSVC có decision score; muốn có xác suất cần calibration. Confidence LR giúp từ chối các câu OOC này, nhưng chất lượng calibration chưa được đo.

Confidence là posterior của mô hình trên 7 intent; biểu đồ chưa chứng minh xác suất được calibration đúng.

# Gõ sai gần như không ảnh hưởng; câu diễn đạt lại làm P@1 giảm còn 0,71




## Vì sao typo nhẹ

Generator của đề chỉ đảo 2 chữ cái liền nhau trong 1 từ. Điểm cosine của tài liệu đúng giảm khoảng 0,05 nhưng thứ hạng không đổi.

## Vì sao paraphrase khó

Cùng ý nhưng ít từ chung. Dù vậy 33/35 câu vẫn có tài liệu đúng trong top 3.

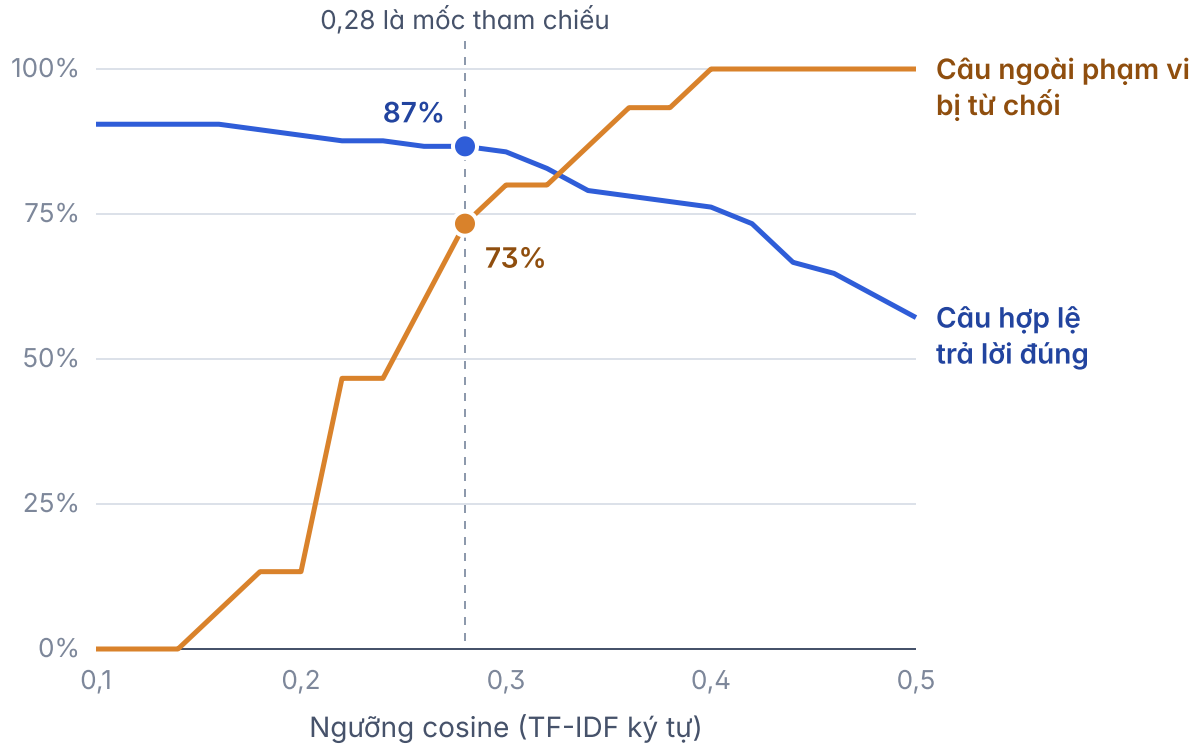
## Bốn chỉ số theo loại câu

| Loại câu | MRR | P@1 | P@3 | Intent |
|---|---|---|---|---|
| normal | 1,000 | 1,000 | 0,333 | 100% |
| paraphrase | 0,829 | 0,714 | 0,314 | 91,4% |
| typo | 1,000 | 1,000 | 0,333 | 100% |

P@3 tối đa là 0,333 vì mỗi câu chỉ có 1 tài liệu đúng.

35 câu normal có trong dữ liệu huấn luyện intent. Intent paraphrase: 32/35. Kết quả cấu hình cố định.

# Cổng intent tạo cải thiện trên benchmark; cosine giữ vai trò mức sàn




## Tắt từng cổng, giữ ngưỡng cố định

| Quy tắc từ chối | Đúng / 120 | OOC |
|---|---|---|
| Không từ chối | 95 | 0/15 |
| Chỉ cosine, s ≥ 0,15 | 96 | 1/15 |
| Chỉ intent, p ≥ 0,34 | 108 | 15/15 |
| Cả hai cổng | 108 | 15/15 |

> Cổng intent tạo cải thiện quan sát được. Thêm cosine sàn chưa tăng accuracy ở đây. Riêng cosine 0,28: đúng 102/120, chặn 11/15 OOC.

Tái lập từ code đã tích hợp trên benchmark đã xem. Kết quả cấu hình cố định, chưa phải ước lượng cross-validation.

# Cả 10 lỗi xếp hạng đều là câu diễn đạt lại: máy khớp từ, không hiểu nghĩa

`Two of my finals overlap on the same day - who do I tell?`

**Cần** faq_exam_02: two of my final exams are scheduled at the same time

**Trả về** faq_class_schedule_02: two of my classes overlap in time

`What's the process for signing up for courses at Hanoi University?`

**Cần** faq_course_registration_01: how do I register for classes

**Trả về** faq_class_schedule_08: class schedule ... university holidays

`My laptop won't join the campus Wi-Fi - what should I check?`

**Cần** faq_technical_support_02: can't connect to the campus Wi-Fi

**Trả về** notice_technical_support_04: Laptop Loan Program

## 7 trên 10 lỗi chỉ lệch một bậc

Tài liệu đúng nằm ở hạng 2. Hiện thêm top-3 cho người dùng là đã thấy câu trả lời.

## Hướng sửa cho bản final

Từ điển đồng nghĩa cho domain (full ↔ no open seats, conflict ↔ overlap), tăng trọng số phần câu hỏi so với phần trả lời, giới hạn tìm kiếm trong intent dự đoán.

# Demo trực tiếp: 3 câu trả lời đúng, 2 câu bị từ chối đúng, 1 câu sai để thấy giới hạn

| Câu gõ vào | Kết quả | Điều cần nói |
|---|---|---|
| `How do I reset my Student Portal password?` | faq_technical_support_01, 0,54 | Trường hợp chuẩn |
| `How do I reset my Sutdent Portal password?` | faq_technical_support_01, 0,53 | Gõ sai chỉ giảm điểm chút ít |
| `I forgot my Student Portal password - how do I reset it?` | faq_technical_support_01, 0,51 | Diễn đạt lại, còn đủ từ chung |
| `What's the best restaurant near campus for vegan food?` | Từ chối, tin cậy 31% | Cổng intent chặn câu ngoài phạm vi |
| `Can I rent a kayak from the campus recreation center?` | Từ chối, tin cậy 29% | Cosine 0,39, chỉ cổng intent mới chặn được |
| `Two of my finals overlap on the same day - who do I tell?` | Sai: faq_class_schedule_02 | Không biết overlap = conflict |

# Ba lựa chọn cuối cùng, và những gì con số chưa nói

| Bước | Chọn | Kết quả |
|---|---|---|
| Retrieval | TF-IDF n-gram ký tự 3–5 + cosine | MRR 0,943 |
| Intent | TF-IDF + Logistic Regression | 97,1% |
| Từ chối | Cosine sàn + độ tin cậy intent | 90% (108/120) |

Cấu hình mẫu gọn, giải thích được và phù hợp ràng buộc cổ điển. Cổng intent tạo cải thiện quan sát được; cosine giữ vai trò mức sàn similarity.

## Hướng cho bản final

- Từ điển đồng nghĩa cho domain để xử lý câu diễn đạt lại.
- Đánh trọng số riêng cho phần câu hỏi và phần trả lời.
- Giao diện Streamlit có thanh trượt ngưỡng và trích dẫn nguồn tài liệu.

## Giới hạn

- Cấu hình mẫu đã nhìn vào benchmark trong quá trình nghiên cứu. Chưa đo khả năng tổng quát hóa trên truy vấn mới.
- Chỉ 15 câu ngoài phạm vi; câu tự tin nhất được 0,33, sát ngưỡng 0,34.
- Typo trong bộ test rất nhẹ, chưa thử được lỗi gõ nặng hơn.
- Mô hình không hiểu từ đồng nghĩa: paraphrase chỉ đúng 71% ở hạng 1.

# Cảm ơn thầy và các bạn

Mời đặt câu hỏi cho nhóm...

**Nguyễn Đạt Vinh**, **Lương Việt Anh**, **Nguyễn Ánh Dương**

Code và số liệu: starter/student_core.py, scripts/evaluate.py